RECORDLY

Organisaatiolaajuinen RAG-avustaja ohjeille ja turvallisuusprotokollille

Nopeat, lähteistetyt vastaukset suomeksi omassa pilvessänne ja chat-työkalussanne. Kulut hallinnassa, Q1-jäädytystä kunnioittaen.

Tarjous Tiina Vartiaiselle, Development Manager for Data and Analytics · Recordly Oy · Helsinki

Tekninen ratkaisu: avustaja rakennetaan teidän pilveenne

Kaikki osat ajetaan teidän tenantissanne ja kytketään teidän chat-työkaluunne. Palvelunimet sovitaan vaiheessa 0, kun pilvi, chat-työkalu ja nykyinen dataympäristö on nimetty.

VAIHE	MITÄ TAPAHTUU	SUOJA
1. Lähteet	Ohjeet, turvallisuusprotokollat ja toimintadokumentit nykyisestä dataympäristöstänne	Dokumenttivarasto: lähde, omistaja, versio, päiväys
2. Poiminta ja pilkonta	Teksti ja rakenne irti, jaetaan kappaleisiin	**Muutostunnistus** (tiiviste tai muokkauspäivä): vain muuttunut sisältö käsitellään uudelleen
3. Indeksi	Vektori- ja avainsanahaku, suomen taivutus ja yhdyssanat huomioiden	Korvatut versiot suljetaan pois
4. Haku	Haku rajataan käyttäjän lähdeoikeuksien mukaan	Oikeudet periytyvät lähteestä; testataan ennen käyttöönottoa
5. Vastaus	Vastaus vain löydetyistä kohdista, **lähdeviite, dokumentin versio ja päiväys**	Heikko näyttö: ei arvausta, ohjaus dokumentin omistajalle
6. Chat-työkalu	Kysyminen suomeksi siinä työkalussa, jota väki jo käyttää	Virheellisen vastauksen ilmoituspainike

Ei lisäominaisuuksia: ei agentteja, ei automaattisia toimia, ei ennusteita. Avustaja vastaa ja viittaa; se ei anna eikä muuta toimintaohjeita.

Kulut hallintaan: vektoripäivitys ei enää yllätä laskulla

Ajastettu täysi uudelleenindeksointi on tyypillinen laskun syy. Korvaamme sen rajatulla, mitatulla päivityksellä.

KUSTANNUSVIPU	HALLINTA
Vektoripäivitys	Inkrementaalinen, muutostunnistuksella; ei kokonaan uudelleen upotettavia ajoja
Ajon katto	Ajokohtainen ja kuukausikohtainen budjetti; ajastus ja enimmäismäärä sovitaan teidän kanssanne
Hälytys ja pysäytys	Budjettihälytys kynnyksillä, **kova pysäytys** ylityksessä, kill switch päivitysajolle
Upotuskutsut ja indeksin koko	Uudelleenupotus vain muuttuneille kappaleille; vanhat versiot poistetaan indeksistä
Mallin tokenit per kysymys	Kappalemäärän raja per vastaus; kustannus per kysymys mitataan
Näkyvyys	Kustannus per ajo ja per kuukausi raportoidaan BI-työkalussanne

Aiemman pilotin asetukset ja laskupiikin laukaisija käydään läpi vaiheessa 0: uudelleen käytetään vain se, mikä oli turvallista.

Suomen kielen laatu mitataan, ei luvata

"Täysi tuki suomen kielen vivahteille" osoitetaan teidän omilla dokumenteillanne ja teidän väkenne kysymyksillä.

SUOMENKIELINEN ARVIOINTIJOUKKO

- Kysymykset **teidän dokumenteistanne**: taivutusmuodot, yhdyssanat, alan sanasto
- Kirjoitettu niin kuin kunnossapitotyöntekijät ja laitosvalvojat kysyvät
- Vastausten arvioijina **dokumenttien omistajat** teiltä
- Upotus- ja vastausmallit valitaan **mittaamalla suomella**, ei oletuksella
- Malli on vaihdettavissa abstraktiokerroksen takaa

MITTARI JA PORTTI

- **Lähtötaso mitataan ensin:** haun osuvuus, vastauksen oikeellisuus, viitteen oikeellisuus, kieltäytyminen heikolla näytöllä
- **Hyväksymisraja sovitaan lähtötason jälkeen** yhdessä teidän kanssanne, ei etukäteen arvaten
- Ajetaan uudelleen ennen jokaista aaltoa sekä jokaisen päivityksen ja mallimuutoksen jälkeen
- Pilotin virhetaso raportoidaan avoimesti: emme lupaa "nolla virhettä"

Pilotti ensin, sitten aallot: aikataulu ja Q1-jäädytys

Rakennus ja testaus ei-tuotannossa ennen Q1:tä. Tuotantoon ei kosketa jäädytyksen aikana.

VAIHE	SISÄLTÖ	PORTTI
0 • Lähde- ja suomi-koe	Dokumenttien inventaario ja laatunäyte (skannaukset, kaksoiskappaleet, vanhentuneet versiot); ensimmäinen suomen mittaus	**Go/no-go:** mitä indeksoidaan
1 • Pilottiviipale	Muutama dokumenttikokoelma ja muutama käyttäjäryhmä; oikeudet, viitteet ja kustannusvalvonta käytössä	Arviointiportti ja kustannus suunnitelmassa
2 • Aallot	Kokoelmat ja käyttäjäryhmät laajenevat aalloittain kohti koko 260 hengen organisaatiota	Portti ennen jokaista aaltoa
Q1-jäädytys	**Tuotantomuutoksia ei tehdä.** Kehitys ja testaus ei-tuotannossa jatkuvat; käyttöönotto-ikkunat ennen jäädytystä ja sen päätyttyä	Jäädytyksen laajuus ja päivät vahvistetaan vaiheessa 0

Jos jäädytys kattaa myös uuden botin chat-työkalussa, se ajoitetaan ikkunaan ennen jäädytystä tai sen jälkeen. Jäädytyksen aikana vain luku -käyttö tai ei-tuotantopilotti vain, jos sääntönne sallivat.

Mitä emme vielä tiedä, ja miten ratkaisemme sen

TUNTEMATON	MIKSI SILLÄ ON VÄLIÄ	RATKAISU
Mikä pilvi, mitkä alueet sallittu	Palveluvalinnat ja käsittelysijainti	Vaihe 0, ensimmäinen viikko
Chat-työkalu: sallitaanko omat botit, kuka hyväksyy	Käyttöliittymän toteutus ja aikataulu	Vaihe 0
Dokumenttien sijainti, muoto, määrä ja kieli	Indeksoinnin työmäärä, skannausten tekstintunnistus	Inventaario ja laatunäyte
Lähdeoikeudet ja tunnistautuminen	Käyttäjäryhmäsuodatus haussa	Oikeuskartoitus; jos oikeuksia ei voi lukea, pilotti yhdellä kaikille avoimella kokoelmalla
Q1-jäädytyksen laajuus ja päivät	Käyttöönotto-ikkunat	Vahvistus teiltä vaiheessa 0
Aiemman pilotin rakenne ja laskupiikki	Uudelleenkäyttö vai korvaus	Läpikäynti yhdessä
Kuka ylläpitää dokumentit ja palvelun käyttöönoton jälkeen	Vastausten tuoreus; hälytysten omistus	Nimetty omistaja per kokoelma; ylläpitäjä sovitaan
Kyselylokien säilytys, henkilötiedot kysymyksissä	Auditointi ja tietosuoja	Linjataan vaiheessa 0

Rehellinen rajaus: emme sitoudu kattamaan lähteitä, joiden laatua emme ole nähneet. Vaiheen 0 portti päättää.

Toimitettavat ja mitä tarvitsemme teiltä

TOIMITETTAVAT

- **D1 • Vaihe 0:** lähde- ja laatuinventaario, suomen lähtötaso, go/no-go
- **D2:** RAG-avustaja pilottiviipaleelle teidän pilvessänne ja chat-työkalussanne, lähdeviitteineen
- **D3:** suomenkielinen arviointijoukko ja ajettava mittaus
- **D4:** kustannusvalvonta: budjetit, hälytykset, kova pysäytys, raportti BI-työkalussanne
- **D5:** aaltokohtainen käyttöönotto Q1-jäädytys huomioiden
- **D6:** suomenkieliset käyttö- ja ylläpito-ohjeet sekä koulutus kunnossapitoväelle ja laitosvalvojille
- **D7:** koodi ja infrastruktuuri teidän repoissanne ja tenantissanne

TARVITSEMME TEILTÄ

- Pilven, chat-työkalun ja BI-työkalun tiedot sekä pääsy ei-tuotantoympäristöön
- Lukuoikeus pilottikokoelmiin ja tieto lähteiden oikeusmallista
- **Dokumenttien omistajat arvioijiksi:** rajattu, ennalta sovittu aika; ei jatkuvaa parityötä
- Q1-jäädytyksen laajuus ja päivät
- Tieto aiemmasta pilotista ja laskupiikistä
- Nimetty vastuuhenkilö palvelulle käyttöönoton jälkeen

Mittaa ensin. Pilotoi pienesti. Älä koske tuotantoon talven huipulla.

Suomenkielinen, lähteistetty avustaja omassa pilvessänne, kulut hallinnassa

Recordly Oy · Helsinki