RECORDLY

Organisaatiolaajuinen RAG-avustaja ohjeille ja turvallisuusprotokollille

Nopeat, lähteistetyt vastaukset suomeksi teidän pilvessänne ja chat-työkalussanne, jos se sallii omat botit. Kulut hallinnassa, Q1-jäädytystä kunnioittaen.

Tarjous Tiina Vartiaiselle, Development Manager for Data and Analytics · Recordly Oy · Helsinki

Tekninen ratkaisu: avustaja rakennetaan teidän pilveenne

Kaikki osat ajetaan teidän tenantissanne tai sen sallimalla alueella; mallikäyttö vahvistetaan vaiheessa 0. Palvelunimet sovitaan, kun pilvi, chat-työkalu ja dataympäristö on nimetty.

ARVIOINTISILMUKKA: suomenkielinen arviointijoukko ajetaan ennen jokaista aaltoa ja jokaisen päivityksen tai mallimuutoksen jälkeen. Dokumenttien omistajat arvioivat.

1 · LÄHTEET
Ohjeet, turvallisuusprotokollat, toimintadokumentit. Lähde, omistaja, versio, päiväys

→

2 · POIMINTA JA PILKONTA
Teksti irti, kappaleiksi. **Muutostunnistus:** vain muuttunut käsitellään uudelleen

→

3 · INDEKSI
Vektori- ja avainsanahaku, suomen taivutus ja yhdyssanat. Korvatut versiot pois

→

4 · HAKU
Rajataan käyttäjän lähdeoikeuksien mukaan. Testataan ennen käyttöönottoa

→

5 · VASTAUS
Vain löydetyistä kohdista: **lähde, versio, päiväys**. Heikko näyttö: ei arvausta, ohjaus omistajalle

→

6 · CHAT-TYÖKALU
Kysyminen suomeksi. Virheilmoituspainike. Jos omat botit eivät onnistu: vaihtoehtoinen pääsy sovitaan vaiheessa 0

KUSTANNUSVALVONTA: ajon ja kuukauden budjetti, hälytys, kova pysäytys ja kill switch päivitysajolle (seuraava sivu)

Ei lisäominaisuuksia: ei agentteja, ei automaattisia toimia, ei ennusteita. Avustaja vastaa ja viittaa; se ei anna eikä muuta toimintaohjeita.

Kulut hallintaan: vektoripäivitys ei enää yllätä laskulla

Ajastettu täysi uudelleenindeksointi on tyypillinen laskun syy. Korvaamme sen rajatulla, mitatulla päivityksellä.

KUSTANNUSVIPU	HALLINTA
Vektoripäivitys	Inkrementaalinen, muutostunnistuksella; ei kokonaan uudelleen upotettavia ajoja
Ajon katto	Ajokohtainen ja kuukausikohtainen budjetti; ajastus ja enimmäismäärä sovitaan teidän kanssanne
Hälytys ja pysäytys	Budjettihälytys kynnyksillä, **kova pysäytys** ylityksessä, kill switch päivitysajolle. **Kova pysäytys pysäyttää vain päivitysajon; kysymyksiin vastaaminen jatkuu.**
Upotuskutsut ja indeksin koko	Uudelleenupotus vain muuttuneille kappaleille; vanhat versiot poistetaan indeksistä
Mallin tokenit per kysymys	Kappalemäärän raja per vastaus; kustannus per kysymys mitataan
Näkyvyys	Kustannus per ajo ja per kuukausi raportoidaan BI-työkalussanne, jos se soveltuu; muuten pilven kustannusnäkymässä

Aiemman pilotin asetukset ja laskupiikin laukaisija käydään läpi vaiheessa 0: uudelleen käytetään vain se, mikä oli turvallista.

Suomen kielen laatu mitataan, ei luvata

"Täysi tuki suomen kielen vivahteille" osoitetaan teidän omilla dokumenteillanne ja teidän väkenne kysymyksillä.

SUOMENKIELINEN ARVIOINTIJOUKKO

- Kysymykset **teidän dokumenteistanne**: taivutusmuodot, yhdyssanat, alan sanasto
- Kirjoitettu niin kuin kunnossapitotyöntekijät ja laitosvalvojat kysyvät
- Vastausten arvioijina **dokumenttien omistajat** teiltä
- Upotus- ja vastausmallit valitaan **mittaamalla suomella**, ei oletuksella
- Malli on vaihdettavissa abstraktiokerroksen takaa
- Ruotsin- ja englanninkielisen sisällön laajuus ja mittaus sovitaan vaiheessa 0

MITTARI JA PORTTI

- **Lähtötaso mitataan ensin:** haun osuvuus, vastauksen oikeellisuus, viitteen oikeellisuus, kieltäytyminen heikolla näytöllä
- **Hyväksymisraja sovitaan lähtötason jälkeen** yhdessä teidän kanssanne, ei etukäteen arvaten
- Ajetaan uudelleen ennen jokaista aaltoa sekä jokaisen päivityksen ja mallimuutoksen jälkeen
- **Vastausaika (mediaani ja p95)** mitataan pilotissa chat-työkalussa; tavoite sovitaan lähtötason jälkeen
- Pilotin virhetaso raportoidaan avoimesti: emme lupaa "nolla virhettä"

Pilotti ensin, sitten aallot: aikataulu ja Q1-jäädytys

Rakennus ja testaus ei-tuotannossa ennen Q1:tä, noin 8 viikon rakennusikkuna. Tuotantoon ei kosketa jäädytyksen aikana.

Vko 1-2 · Vaihe 0
Inventaario, laatunäyte, suomen lähtötaso, Go/no-go

Vko 3-8 · Pilottiviipale ei-tuotannossa
Oikeudet, viitteet, kustannusvalvonta, arviointi; testaus ennen Q1:tä

Tuotantoikkuna
vain jos Go/no-go täyttyy

Q1-jäädytys: ei tuotantomuutoksia
Kehitys ja testaus ei-tuotannossa jatkuvat

Jäädytyksen jälkeen
Tuotantopilotti ja aallot

VAIHE	SISÄLTÖ	PORTTI
0 • Lähde- ja suomi-koe (vko 1-2)	Dokumenttien inventaario ja laatunäyte; ensimmäinen suomen mittaus	**Go/no-go:** mitä indeksoidaan
1 • Pilottiviipale (ei-tuotannossa ennen Q1:tä)	Muutama kokoelma ja käyttäjäryhmä; oikeudet, viitteet, kustannusvalvonta	Arviointiportti ja kustannus suunnitelmassa
2 • Aallot	Kokoelmat ja käyttäjäryhmät laajenevat aalloittain kohti 260 hengen organisaatiota	Portti ennen jokaista aaltoa

Tuotantoikkuna ennen jäädytystä vain, jos Go/no-go täyttyy; muuten tuotantopilotti jäädytyksen jälkeen. Jäädytyksen laajuus ja päivät vahvistetaan vaiheessa 0. Jos se kattaa myös uuden botin chat-työkalussa, botti ajoitetaan ikkunaan ennen jäädytystä tai sen jälkeen.

Mitä emme vielä tiedä, ja miten ratkaisemme sen

TUNTEMATON	MIKSI SILLÄ ON VÄLIÄ	RATKAISU
Mikä pilvi, mitkä alueet sallittu; sijaitseeko mallikäyttö tenantissanne	Palveluvalinnat ja käsittelysijainti	Vaihe 0, ensimmäinen viikko
Chat-työkalu: sallitaanko omat botit, kuka hyväksyy	Käyttöliittymän toteutus ja aikataulu	Vaihe 0; jos ei, vaihtoehtoinen pääsy sovitaan
Dokumenttien sijainti, muoto, määrä ja kieli	Indeksoinnin työmäärä, skannausten tekstintunnistus	Inventaario ja laatunäyte
Lähdeoikeudet ja tunnistautuminen	Käyttäjäryhmäsuodatus haussa	Oikeuskartoitus; jos oikeuksia ei voi lukea, pilotti yhdellä kaikille avoimella kokoelmalla
Q1-jäädytyksen laajuus ja päivät	Käyttöönotto-ikkunat	Vahvistus teiltä vaiheessa 0
Aiemman pilotin rakenne ja laskupiikki	Uudelleenkäyttö vai korvaus	Läpikäynti yhdessä
Kuka ylläpitää dokumentit ja palvelun käyttöönoton jälkeen	Vastausten tuoreus; hälytysten omistus	Nimetty omistaja per kokoelma; ylläpitäjä sovitaan
Kyselylokien säilytys, henkilötiedot kysymyksissä	Auditointi ja tietosuoja	Ehdotus: lyhyt säilytys ja henkilötietojen minimointi; linjataan vaiheessa 0

Rehellinen rajaus: emme sitoudu kattamaan lähteitä, joiden laatua emme ole nähneet. Vaiheen 0 portti päättää.

Toimitettavat ja mitä tarvitsemme teiltä

TOIMITETTAVAT

- **D1 • Vaihe 0:** lähde- ja laatuinventaario, suomen lähtötaso, go/no-go
- **D2:** RAG-avustaja pilottiviipaleelle teidän pilvessänne ja chat-työkalussanne (tai sovitussa vaihtoehtoisessa pääsyssä), lähdeviitteineen
- **D3:** suomenkielinen arviointijoukko ja ajettava mittaus
- **D4:** kustannusvalvonta: budjetit, hälytykset, kova pysäytys, raportti BI-työkalussanne tai pilven kustannusnäkymässä
- **D5:** aaltokohtainen käyttöönotto Q1-jäädytys huomioiden
- **D6:** suomenkieliset käyttö- ja ylläpito-ohjeet sekä koulutus kunnossapitoväelle ja laitosvalvojille
- **D7:** koodi ja infrastruktuuri teidän repoissanne ja tenantissanne

TARVITSEMME TEILTÄ

- Pilven, chat-työkalun ja BI-työkalun tiedot sekä pääsy ei-tuotantoympäristöön
- Lukuoikeus pilottikokoelmiin ja tieto lähteiden oikeusmallista
- **Dokumenttien omistajat arvioijiksi:** rajattu, ennalta sovittu aika; ei jatkuvaa parityötä
- Q1-jäädytyksen laajuus ja päivät
- Tieto aiemmasta pilotista ja laskupiikistä
- Nimetty vastuuhenkilö palvelulle käyttöönoton jälkeen

Mittaa ensin. Pilotoi pienesti. Älä koske tuotantoon talven huipulla.

Suomenkielinen, lähteistetty avustaja teidän pilvessänne, kulut hallinnassa

Recordly Oy · Helsinki